w-python-numpy-grundlagen

Lukas Arnold Simone Arnold Matthias Baitsch Marc Fehr Sebastian Seipel Florian Bagemihl Maik Poetzsch

2024-06-21

Inhaltsverzeichnis

Pr	reamble	4
Int	Voraussetzungen Verwendete Pakete und Datensätze Bearbeitungszeit Lernziele	5 5 5 5
1	Einführung NumPy 1.1 Vorteile & Nachteile	6 6 7 7
2	Erstellen von NumPy arrays	8
3	Größe, Struktur und Typ	12
4 5	Rechnen mit Arrays 4.1 Arithmetische Funktionen	15 15 16 17 20
6 7	Array Manipulation 6.1 Ändern der Form	23 23 25 25 25
•	7.1 Lesen von Dateien	28 29
8	Arbeiten mit Bildern	32
9	Lernzielkontrolle	38

	Aufgabe 2	38
	Aufgabe 3	
	Aufgabe 4	39
	Aufgabe 5	39
	Aufgabe 6	39
	Aufgabe 7	39
	Aufgabe 8	39
	Aufgabe 9	40
	Aufgabe 10	40
	Aufgabe 1	40
	Aufgabe 2	40
	Aufgabe 3	41
	Aufgabe 4	41
	Aufgabe 5	41
10	Übung	42
	10.1 Aufgabe 1 Filmdatenbank	42
	10.2 Aufgabe 2 - Kryptographie - Caesar-Chiffre	47

Preamble



Bausteine Computergestützter Datenanalyse. "Numpy Grundlagen" von Marc Fehr ist lizensiert unter CC BY 4.0. Das Werk ist abrufbar unter *Platzhalter>*. Ausgenommen von der Lizenz sind alle Logos und anders gekennzeichneten Inhalte. 2024

Intro

Voraussetzungen

- Grundlagen Python
- Einbinden von zusätzlichen Paketen
- Plotten mit Matplotlib

Verwendete Pakete und Datensätze

- NumPy
- Matplotlib

Bearbeitungszeit

Geschätzte Bearbeitungszeit: 42 Stunden

Lernziele

- Einleitung: was ist NumPy, Vor- und Nachteile
- Nutzen des NumPy-Moduls
- Erstellen von NumPy-Arrays
- Slicing
- Referenzen
- Lesen und schreiben von Dateien
- Bilder

1 Einführung NumPy

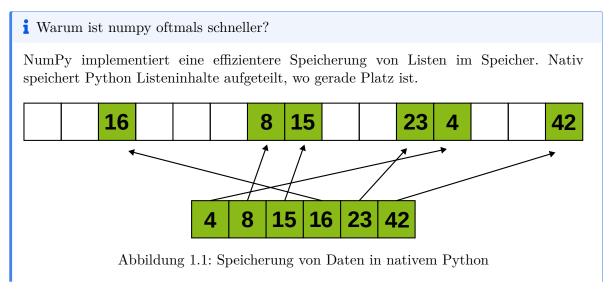
NumPy ist eine leistungsstarke Bibliothek für Python, die für numerisches Rechnen und Datenanalyse verwendet wird. Daher auch der Name NumPy, ein Akronym für "Numerisches Python" (englisch: "Numeric Python" oder "Numerical Python"). NumPy selbst ist hauptsächlich in der Programmiersprache C geschrieben, weshalb NumPy generell sehr schnell ist.

NumPy bietet ein effizientes Arbeiten mit kleinen und großen Vektoren und Matrizen, die so ansonsten nur umständlich in nativem Python implementiert werden würden. Dabei bietet NumPy auch die Möglichkeit, einfach mit Vektoren und Matrizen zu rechnen, und das auch für sehr große Datenmengen.

Diese Einführung wird Ihnen dabei helfen, die Grundlagen von NumPy zu verstehen und zu nutzen.

1.1 Vorteile & Nachteile

Fast immer sind Operationen mit Numpy Datenstrukturen schneller. Im Gegensatz zu nativen Python Listen kann man dort aber nur einen Datentyp pro Liste speichern.



Dagegen werden NumPy Arrays und Matritzen zusammenhängend gespeichert, was einen effizienteren Datenaufruf ermöglicht.

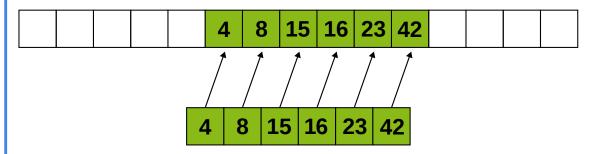


Abbildung 1.2: Speicherung von Daten bei Numpy

Dies bedeutet aber auch, dass es eine Erweiterung der Liste deutlich schneller ist als eine Erweiterung von Arrays oder Matrizen. Bei Listen kann jeder freie Platz genutzt werden, während Arrays und Matrizen an einen neuen Ort im Speicher kopiert werden müssen.

1.2 Einbinden des Pakets

NumPy wird über folgende Zeile eingebunden. Dabei hat sich global der Standard entwickelt, als Alias np zu verwenden.

import numpy as np

1.3 Referenzen

Sämtliche hier vorgestellten Funktionen lassen sich in der (englischen) NumPy-Dokumentation nachschlagen: Dokumentation

2 Erstellen von NumPy arrays

Typischerweise werden in Python Vektoren durch Listen und Matrizen durch geschachtelte Listen ausgedrückt. Beispielsweise würde man den Vektor

$$(1,2,3,4,5,6) \qquad \text{und die Matrix} \qquad \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}$$

nativ in Python so erstellen:

```
liste = [1, 2, 3, 4, 5, 6]
matrix = [[1, 2, 3], [4, 5, 6]]
print(liste)
print(matrix)
```

```
[1, 2, 3, 4, 5, 6]
[[1, 2, 3], [4, 5, 6]]
```

Möchte man jetzt NumPy Arrays verwenden benutzt man den Befehl np.array().

```
liste = np.array([1, 2, 3, 4, 5, 6])
matrix = np.array([[1, 2, 3], [4, 5, 6]])
print(liste)
print(matrix)
```

```
[1 2 3 4 5 6]
[[1 2 3]
[4 5 6]]
```

Betrachtet man die Ausgaben der print() Befehle fallen zwei Sachen auf. Zum einen fallen die Kommata weg und zum anderen wird die Matrix passend ausgegeben.

Es gibt auch die Möglichkeit, höherdimensionale Arrays zu erstellen. Dabei wird eine neue Ebene der Verschachtelung benutzt. Im folgenden Beispiel wird eine drei-dimensionale Matrix erstellt.

```
matrix_3d = np.array([[[1, 2, 3], [4, 5, 6]], [[7, 8, 9], [10, 11, 12]]])
```

Es gilt als "good practice" Arrays immer zu initialisieren. Dafür bietet NumPy drei Funktionen um vorinitialisierte Arrays zu erzeugen. Alternativ können Arrays auch mit festgesetzten Werten initialisiert werden. Dafür kann entweder die Funktion np.zeros() verwendet werden die alle Werte auf 0 setzt, oder aber np.ones() welche alle Werte mit 1 initialisiert. Der Funktion wird die Form im Format [Reihen, Spalten] übergeben. Möchte man alle Einträge auf einen spezifischen Wert setzen, kann man den Befehl np.full() benutzen.

• Wie könnte man auch Arrays die mit einer Zahl x gefühlt sind erstellen?

Der Trick beseht hierbei ein Array mit np.ones() zu initialisiere und dieses Array dann mit der Zahl x zu multiplizieren. Im folgenden Beispiel ist x=5

Möchte man zum Beispiel für eine Achse in einem Plot einen Vektor mit gleichmäßig verteilten Werten erstellen, bieten sich in NumPy zwei Möglichkeiten. Mit den Befehlen np.linspace(Start,Stop,#Anzahl Werte) und np.arrange(Start,Stop,Abstand zwischen Werten) können solche Arrays erstellt werden.

```
np.linspace(0,1,11)
```

array([0., 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1.])

np.arange(0,10,2)

array([0, 2, 4, 6, 8])

? Zwischenübung: Array Erstellung

Erstellen Sie jeweils ein NumPy-Array, mit dem folgenden Inhalt:

- 1. mit den Werten 1, 7, 42, 99
- 2. zehn mal die Zahl 5
- 3. mit den Zahlen von 35 bis einschließlich 50
- 4. mit allen geraden Zahlen von 20 bis einschließlich 40
- 5. eine Matrix mit 5 Spalten und 4 Reihen mit dem Wert 4 an jeder Stelle
- 6. mit 10 Werten die gleichmäßig zwischen 22 und einschlieslich 40 verteilt sind

```
Lösung
# 1.
print(np.array([1, 7, 42, 99]))
[ 1 7 42 99]
# 2.
print(np.full(10,5))
[5 5 5 5 5 5 5 5 5 5]
# 3.
print(np.arange(35, 51))
[35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50]
print(np.arange(20, 41, 2))
[20 22 24 26 28 30 32 34 36 38 40]
# 5.
print(np.full([4,5],4))
[[4 4 4 4 4]
 [4 \ 4 \ 4 \ 4 \ 4]
 [4 \ 4 \ 4 \ 4 \ 4]
 [4 \ 4 \ 4 \ 4 \ 4]
# 6.
print(np.linspace(22, 40, 10))
[22. 24. 26. 28. 30. 32. 34. 36. 38. 40.]
```

3 Größe, Struktur und Typ

Wenn man sich nicht mehr sicher ist, welche Struktur oder Form ein Array hat oder oder diese Größen zum Beispiel für Schleifen nutzen möchte, bietet NumPy folgende Funktionen für das Auslesen dieser Größen an.

```
matrix = np.array([[1, 2, 3], [4, 5, 6]])
```

np.shape() gibt die Längen der einzelnen Dimension in Form einer Liste zurück.

```
np.shape(matrix)
```

(2, 3)

Die native Python Funktion len() gibt dagegen nur die Länge der ersten Dimension, also die Anzahl der Elemente in den äußeren Klammern wieder.

```
len(matrix)
```

2

Die Funktion np.ndym()gibt im Gegensatz zu np.shape() nur die Anzahl der Dimensionen zurück.

```
np.ndim(matrix)
```

2

• Die Ausgabe von np.ndim() kann mit np.size() und einer nativen Python Funktion erreicht werden. Wie?

np.ndim() gibt die Länge der Liste von np.shape() aus

```
len(np.shape(matrix))
```

Möchte man die Anzahl aller Elemente in einem Array ausgeben kann man die Funktion np.size() benutzen.

```
np.size(matrix)
```

6

NumPy Arrays können verschiedene Datentypen beinhalten. Im folgenden haben wir drei verschiedene Arrays mit einem jeweils anderen Datentypen.

```
typ_a = np.array([1, 2, 3, 4, 5])
typ_b = np.array([0.1, 0.2, 0.3, 0.4, 0.5])
typ_c = np.array(["Montag", "Dienstag", "Mittwoch"])
```

Mit der Methode np.dtype können wir den Datentypen von Arrays ausgeben lassen. Meist wird dabei der Typ plus eine Zahl ausgegeben, welche die zum Speichern benötigte Bytezahl angibt. Das Array typ_a beinhaltet den Datentypen int64, also ganze Zahlen.

```
print(typ_a.dtype)
```

int64

Das Array typ_b beinhaltet den Datentypen float64, wobei float für Gleitkommazahlen steht.

```
print(typ_b.dtype)
```

float64

Das Array typ_c beinhaltet den Datentypen U8, wobei das U für Unicode steht. Hier wird als Unicodetext gespeichert.

```
print(typ_c.dtype)
```

<U8

Im folgenden finden Sie eine Tabelle mit den typischen Datentypen, die sie häufig antreffen.

Tabelle 3.1: Typische Datentypen in NumPy

Datentyp	Numpy Name	Beispiele
Wahrheitswert	bool	[True, False, True]
Ganze Zahl	int	[-2, 5, -6, 7, 3]
positive Ganze Zahlen	uint	[1, 2, 3, 4, 5]
Kommazahlen	float	[1.3, 7.4, 3.5, .5.5]
komplexe zahlen	complex	[-1 + 9j, 2-77j, 72 + 11j]
Textzeichen	U	["montag", "dienstag"]

♥ Zwischenübung: Arrayinformationen auslesen
 Diese Seite muss auf Grund des neuen NumPy Updates überarbeitet werden
 Lösung

4 Rechnen mit Arrays

4.1 Arithmetische Funktionen

Ein großer Vorteil an NumPy ist das Rechnen mit Arrays. Ohne NumPy müsste man entweder eine Schleife oder aber List comprehension benutzen, um mit sämtlichen Werten in der Liste zu rechnen. In NumPy fällt diese Unannehmlichkeit weg.

```
a = np.array([1, 2, 3, 4, 5])
b = np.array([9, 8, 7, 6, 5])
```

Normale mathematische Operationen, wie die Addition, lassen sich auf zwei Arten ausdrücken. Entweder über die np.add() Funktion oder aber simpel über das + Zeichen.

```
np.add(a,b)
array([10, 10, 10, 10])
a + b
```

Für die anderen Rechenarten existieren auch Funktionen: np.subtract(), np.multiply() und np.divide().

Auch für die anderen höheren Rechenoperationen gibt es ebenfalls Funktionen:

- np.exp(a)
- np.sqrt(a)
- np.power(a, 3)

array([10, 10, 10, 10, 10])

- np.sin(a)
- np.cos(a)
- np.tan(a)
- np.log(a)
- a.dot(b)



Arbeiten mit Winkelfunktionen

Wie auch am Taschenrechner birgt das Arbeiten mit den Winkelfunktionen (sin, cos, ...) die Fehlerquelle, dass man nicht mit Radian-Werten, sondern mit Grad-Werten arbeitet. Die Winkelfunktionen in numpy erwarten jedoch Radian-Werte.

Für eine einfache Umrechnung bietet NumPy die Funktionen np.grad2rad() und np.rad2grad().

4.2 Vergleiche

NumPy-Arrays lassen sich auch miteinander vergleichen. Betrachten wir die folgenden zwei Arrays:

```
a = np.array([1, 2, 3, 4, 5])
b = np.array([9, 2, 7, 4, 5])
```

Möchten wir feststellen, ob diese zwei Arrays identisch sind, können wir den ==-Komparator benutzen. Dieser vergleicht die Arrays elementweise.

```
a == b
array([False,
              True, False,
                            True,
```

Es ist außerdem möglich Arrays mit den >- und <-Operatoren zu vergleichen:

```
a < b
```

```
array([ True, False, True, False, False])
```

Möchte man Arrays mit Gleitkommazahlen vergleichen, ist es oftmals nötig, eine gewisse Toleranz zu benutzen, da bei Rechenoperationen minimale Rundungsfehler entstehen können.

```
a = np.array(0.1 + 0.2)
b = np.array(0.3)
a == b
```

False

Für diesen Fall gibt es eine Vergleichsfunktion np.isclose(a,b,atol), wobei atol für die absolute Toleranz steht. Im folgenden Beispiel wird eine absolute Toleranz von 0,001 verwendet.

```
a = np.array(0.1 + 0.2)
b = np.array(0.3)
print(np.isclose(a, b, atol=0.001))
```

True

```
i Warum ist 0.1 + 0.2 nicht gleich 0.3?
```

Zahlen werden intern als Binärzahlen dargestellt. So wie 1/3 nicht mit einer endlichen Anzahl an Ziffern korrekt dargestellt werden kann müssen Zahlen ggf. gerundet werden, um im Binärsystem dargestellt zu werden.

4.3 Aggregatfunktionen

Für verschiedene Auswertungen benötigen wir Funktionen, wie etwa die Summen oder die Mittelwert-Funktion. Starten wir mit einem Beispiel Array a:

```
a = np.array([1, 2, 3, 4, 8])
```

Die Summer wird über die Funktion np.sum() berechnet.

```
np.sum(a)
```

18

Natürlich lassen sich auch der Minimalwert und der Maximalwert eines Arrays ermitteln. Die beiden Funktionen lauten np.min() und np.max().

np.min(a)

1

Möchte man nicht das Maximum selbst, sondern die Position des Maximums bestimmen, wird statt np.max die Funktion np.argmaxverwendet.

Für statistische Auswertungen werden häufig die Funktion für den Mittelwert np.mean(), die Funktion für den Median np.median() und die Funktion für die Standardabweichung np.std()verwendet.

np.mean(a)

3.6

np.median(a)

3.0

np.std(a)

2.4166091947189146



Zwischenübung: Arrayinformationen auslesen

Gegeben sind zwei eindimensionale Arrays a und b: a = np.array([10, 20, 30, 40, 50, 60, 70, 80, 90, 100]) und b = np.array([5, 15, 25, 35, 45, 45, 45, 45])55, 65, 75, 85, 95])

- 1. Erstellen Sie ein neues Array, das die Sinuswerte der addierten Arrays a und b
- 2. Berechnen Sie die Summe, den Mittelwert und die Standardabweichung der Elemente in a.
- 3. Finden Sie den größten und den kleinsten Wert in a und b.

```
Lösung

a = np.array([10, 20, 30, 40, 50, 60, 70, 80, 90, 100])
b = np.array([5, 15, 25, 35, 45, 55, 65, 75, 85, 95])

# 1.

sin_ab = np.sin(a + b)

# 2.

sum_a = np.sum(a)
mean_a = np.mean(a)
std_a = np.std(a)

# 3.

max_a = np.max(a)
min_a = np.min(a)
max_b = np.max(b)
min_b = np.min(b)
```

5 Slicing




Abbildung 5.1: Ansprechen der einzelnen Achsen für den ein-, zwei- und dreidimensionallen Fall inkl. jeweiligem Beispiel

Möchte man jetzt Daten innerhalb eines Arrays auswählen so geschieht das in der Form:

```
liste = np.array([1, 2, 3, 4, 5, 6])
# Auswählen des ersten Elements
liste[0]
```

1

```
# Auswählen des letzen Elements
liste[-1]
```

6

```
# Auswählen einer Reihe von Elementen
liste[1:4]
```

```
array([2, 3, 4])
```

Für zwei-dimensionale Arrays wählt man getrennt durch ein Komma mit einer zweiten Zahl die zweite Dimension aus.

```
matrix = np.array([[1, 2, 3], [4, 5, 6]])
```

```
# Auswählen einer Elements
matrix[1,1]
```

5

Für drei-dimensionale Arrays wählt man getrennt durch ein Komma mit einer weiteren Zahl die dritte Dimension aus. Dabei wird dieses jedoch an die erste Stelle gesetzt.

```
matrix_3d = np.array([[[1, 2, 3], [4, 5, 6]], [[7, 8, 9], [10, 11, 12]]])
print(matrix_3d)
```

```
[[[ 1 2 3]
 [ 4 5 6]]
 [[ 7 8 9]
 [10 11 12]]]
```

```
# Auswählen eines Elements
matrix_3d[1,0,2]
```

9

♀ Zwischenübung: Array-Slicing

Wählen Sie die farblich markierten Bereiche aus dem Array "matrix" mit den eben gelernten Möglichkeiten des Array-Slicing aus.

0	2	11	18	47	33	48	9	31	8	41
1	55	1	8	3	91	56	17	54	23	12
2	19	99	56	72	6	13	34	16	77	56
3	37	75	67	5	46	98	57	19	14	7
4	4	57	32	78	56	12	43	61	3	88
5	96	16	92	18	50	90	35	15	36	97
6	75	4	38	53	1	79	56	73	45	56
7	15	76	11	93	87	8	2	58	86	94
8	51	14	60	57	74	42	59	71	88	52
9	49	6	43	39	17	18	95	6	44	75
	0	1	2	3	4	5	6	7	8	9

Lösung

Rot: matrix[1,3]
Grün: matrix[4:5,2:5]
Pink: matrix[:,7]
Orange: matrix[7,:4]
Blau: matrix[-1,-1]

6 Array Manipulation

6.1 Ändern der Form

Durch verschiedene Funktionen lassen sich die Form und die Einträge der Arrays verändern.

Eine der wichtigsten Array Operationen ist das Transponieren. Dabei werden Reihen in Spalten und Spalten in Reihe umgewandelt.

```
matrix = np.array([[1, 2, 3], [4, 5, 6]])
print(matrix)
```

```
[[1 2 3]
[4 5 6]]
```

Transponieren wir dieses Array nun erhalten wir:

```
print(np.transpose(matrix))
```

[[1 4]

[2 5]

[3 6]]

Haben wir ein nun diese Matrix und wollen daraus einen Vektor erstellen so können wir die Funktion np.flatten() benutzen:

```
vector = matrix.flatten
print(vector)
```

<built-in method flatten of numpy.ndarray object at 0x1040f6bb0>

Um wieder eine zweidimensionale Datenstruktur zu erhalten, benutzen wir die Funktion np.reshape(Ziel, Form)

```
print(np.reshape(matrix, [3, 2]))
```

[[1 2]

[3 4] [5 6]]

Möchten wir den Inhalt eines bereits bestehenden Arrays erweitern, verkleinern oder ändern bietet NumPy ebenfalls die passenden Funktionen.

Haben wir ein leeres Array oder wollen wir ein schon volles Array erweitern benutzen wir die Funktion np.append(). Dabei hängen wir einen Wert an das bereits bestehende Array an.

```
liste = np.array([1, 2, 3, 4, 5, 6])
neue_liste = np.append(liste, 7)
print(neue_liste)
```

```
[1 2 3 4 5 6 7]
```

Gegebenenfalls ist es nötig einen Wert nicht am Ende, sondern an einer beliebigen Position im Array einzufügen. Das passende Werkzeug ist hier die Funktion np.insert(Array, Position, Einschub). Im folgenden Beispiel wird an der dritten Stelle die Zahl 7 eingesetzt.

```
liste = np.array([1, 2, 3, 4, 5, 6])
neue_liste = np.insert(liste, 3, 7)
print(neue_liste)
```

```
[1 2 3 7 4 5 6]
```

Wenn sich neue Elemente einfügen lassen, können natürlich auch Elemente gelöscht werden. Hierfür wird die Funktion np.delete(Array, Position) benutzt, die ein Array und die Position der zu löschenden Funktion übergeben bekommt.

```
liste = np.array([1, 2, 3, 4, 5, 6])
neue_liste = np.delete(liste, 3)
print(neue_liste)
```

```
[1 2 3 5 6]
```

Zuletzt wollen wir uns noch die Verbindung zweier Arrays anschauen. Im folgenden Beispiel wird dabei das Array b an das Array a mithilfe der Funktion np.concatenate((Array a, Array b))angehängt.

```
a = np.array([1, 2, 3, 4, 5, 6])
b = np.array([7, 8, 9, 10])

neue_liste = np.concatenate((a, b))
print(neue_liste)
```

```
[1 2 3 4 5 6 7 8 9 10]
```

6.2 Sortieren von Arrays

NumPy bietet auch die Möglichkeit, Arrays zu sortieren. Im folgenden Beispiel starten wir mit einem unsortierten Array. Mit der Funktion np.sort() erhalten wir ein sortiertes Array.

```
import numpy as np
unsortiert = np.array([4, 2, 1, 6, 3, 5])
sortiert = np.sort(unsortiert)
print(sortiert)
```

[1 2 3 4 5 6]

6.3 Unterlisten mit einzigartigen Werten

Arbeitet man mit Daten bei denen zum Beispiel Projekte Personalnummern zugeordnet werden hat man Daten mit einer endlichen Anzahl an Personalnummern, die jedoch mehrfach vorkommen können wenn diese an mehr als einem Projekt gleichzeitig arbeiten.

Möchte man nun eine Liste die jede Nummer nur einmal enthält, kann die Funtkion np.unique verwendet werden.

```
import numpy as np
liste_mit_dopplungen = np.array([4, 1, 1, 6, 3, 4, 7, 3, 3])
einzigartige_werte = np.unique(liste_mit_dopplungen)
print(einzigartige_werte)
```

[1 3 4 6 7]

Setzt man dann noch die Option return_counts=True kann in einer zweiten Variable gespeichert werden, wie oft jeder Wert vorkommt.

```
import numpy as np
liste_mit_dopplungen = np.array([4, 1, 1, 6, 3, 4, 7, 3, 3])
einzigartige_werte, anzahl = np.unique(liste_mit_dopplungen, return_counts=True)
print(anzahl)
```

[2 3 2 1 1]

? Zwischenübung: Arraymanipulation

Gegeben ist das folgende zweidimensionale Array matrix:

```
matrix = np.array([
    [4, 7, 2, 8],
    [1, 5, 3, 6],
    [9, 2, 4, 7]
])
```

- 1. Ändern Sie die Form des Arrays matrix in ein eindimensionales Array.
- 2. Sortieren Sie das eindimensionale Array in aufsteigender Reihenfolge.
- 3. Ändern Sie die Form des sortierten Arrays in ein zweidimensionales Array mit 2 Zeilen und 6 Spalten.
- 4. Bestimmen Sie die eindeutigen Elemente im ursprünglichen Array matrix und geben Sie diese aus.

Lösung

```
matrix = np.array([
      [4, 7, 2, 8],
      [1, 5, 3, 6],
      [9, 2, 4, 7]
])

# 1. Ändern der Form in ein eindimensionales Array
flat_array = matrix.flatten()

# 2. Sortieren des eindimensionalen Arrays in aufsteigender Reihenfolge
sorted_array = np.sort(flat_array)

# 3. Ändern der Form des sortierten Arrays in ein 2x6-Array
reshaped_array = sorted_array.reshape(2, 6)

# 4. Bestimmen der eindeutigen Elemente im ursprünglichen Array
unique_elements_original = np.unique(matrix)
```

7 Lesen und Schreiben von Dateien

Das Modul numpy stellt Funktionen zum Lesen und Schreiben von strukturierten Textdateien bereit.

7.1 Lesen von Dateien

Zum Lesen von strukturierten Textdateien, z.B. im CSV-Format (comma separated values), kann die np.loadtxt()-Funktion verwendet werden. Diese bekommt als Argumente den einzulesenden Dateinamen und weitere Optionen zur Definition der Struktur der Daten. Der Rückgabewert ist ein (mehrdimensionales) Array.

Im folgenden Beispiel wird die Datei TC01.csv eingelesen und deren Inhalt graphisch dargestellt. Die erste Zeile der Datei wird dabei ignoriert, da sie als Kommentar – eingeleitet durch das #-Zeichen – interpretiert wird.

```
dateiname = '01-daten/TC01.csv'
daten = np.loadtxt(dateiname)

print("Daten:", daten)
print("Form:", daten.shape)

Daten: [20.1 20.1 20.1 ... 24.3 24.2 24.2]
Form: (1513,)

plt.plot(daten)
plt.xlabel('Datenindex')
plt.ylabel('Temperatur in °C');
```




7.2 Schreiben von Dateien

Zum Schreiben von Arrays in Dateien, kann die in numpy verfügbare Funktion np.savetxt() verwendet werden. Dieser müssen mindestens die zu schreibenden Arrays als auch ein Dateiname übergeben werden. Darüber hinaus sind zahlreiche Formatierungs- bzw. Strukturierungsoptionen möglich.

Folgendes Beispiel skaliert die oben eingelesenen Daten und schreib jeden zehnten Wert in eine Datei. Dabei wird auch ein Kommentar (header-Argument) am Anfang der Datei erzeugt. Das Ausgabeformat der Zahlen kann mit dem fmt-Argument angegeben werden. Das Format ähnelt der Darstellungsweise, welche bei den formatierten Zeichenketten vorgestellt wurde.

```
wertebereich = np.max(daten) - np.min(daten)
daten_skaliert = ( daten - np.min(daten) ) / wertebereich
daten_skaliert = daten_skaliert[::10]
```

```
plt.xlabel('Datenindex')
plt.ylabel('Skalierte Temperatur');
```



Beim Schreiben der Datei wird ein mehrzeiliger Kommentar mithilfe des Zeilenumbruchzeichens \n definiert. Die Ausgabe der Gleitkommazahlen wird mit %5.2f formatiert, was 5 Stellen insgesamt und zwei Nachkommastellen entspricht.

Zum Veranschaulichen werden die ersten Zeilen der neuen Datei ausgegeben.

```
# Einlesen der ersten Zeilen der neu erstellten Datei
datei = open(neu_dateiname, 'r')
for i in range(10):
    print( datei.readline() , end='')
datei.close()
```

Daten aus 01-daten/TC01.csv skaliert auf den Beriech0 bis 1

```
# originales Min / Max:20.1/31.1
```

- 0.00
- 0.00
- 0.00
- 0.01
- 0.01
- 0.01
- 0.01
- 0.01

8 Arbeiten mit Bildern

Bilder werden digital als Matrizen gespeichert. Dabei werden pro Pixel drei Farbwerte (rot, grün, blau) gespeichert. Aus diesen drei Farbwerten (Wert 0-255) werden dann alle gewünschten Farben zusammengestellt.

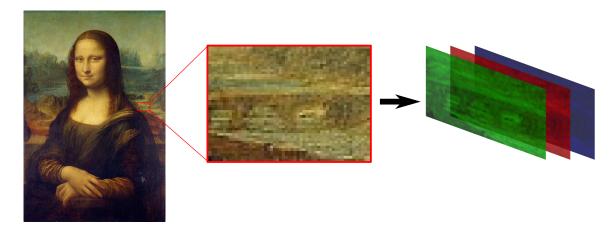


Abbildung 8.1: Ein hochaufgelöstes Bild besteht aus sehr vielen Pixeln. Jedes Pixel enthät 3 Farbwerte, einen für die Fabre Grün, einen für Blau und einen für Rot.

Aufgrund der digitalen Darstellung von Bildern lassen sich diese mit den Werkzeugen von NumPy leicht bearbeiten. Wir verwenden für folgendes Beispiel als Bild die Monas Lisa. Das Bild ist unter folgendem Link zu finden.

Importieren wir dieses Bild nun mit der Funktion imread() aus dem matplotlib-package, sehen wir das es um ein dreidimensionales numpy Array handelt.

```
import matplotlib.pyplot as plt

data = plt.imread("00-bilder/mona_lisa.jpg")
print("Form:", data.shape)
```

Form: (1024, 677, 3)

Schauen wir uns einmal mit der print()-Funktion einen Ausschnitt dieser Daten an.

print(data)

```
[[[ 68 62
           38]
 [ 88 82 56]
 [ 92 87 55]
 . . .
 [ 54 97
           44]
 [ 68 110
           60]
 [ 69 111 63]]
 [[ 65 59
           33]
 [ 68 63 34]
 [ 83 78 46]
 . . .
 [ 66 103 51]
 [ 66 103 52]
 [ 66 102 56]]
 [[ 97 90 62]
 [ 87 80 51]
 [ 78 72 38]
 . . .
 [ 79 106 53]
 [ 62 89 38]
 [ 62 88 41]]
 . . .
 [[ 25 14 18]
 [ 21 10 14]
 [ 20
       9 13]
 . . .
 [ 11
        5
            9]
 [ 11
        5
            9]
 [ 10
            8]]
 [[ 23 12 16]
 [ 23 12 16]
 [ 21 10 14]
  . . .
  [ 11
        5 9]
  [ 11
        5
            9]
```

```
[ 10
             8]]
[[ 22
            15]
       11
 [ 26
       15
            19]
 [ 24
       13
            17]
 [ 11
         5
             9]
         4
             8]
 [ 10
 9
         3
             7]]]
```

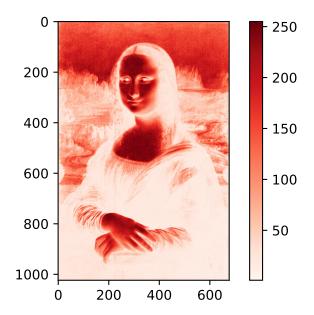
Mit der Funktion plt.imshow kann das Bild in Echtfarben dargestellt werden. Dies funktioniert, da die Funktion die einzelnen Ebenen, hier der letzte Index, des Datensatzes als Farbinformationen (rot, grün, blau) interpretiert. Wäre noch eine vierte Ebene dabei, würde sie als individueller Transparenzwert verwendet worden.

plt.imshow(data)




Natürlich können auch die einzelnen Farbebenen individuell betrachtet werden. Dazu wird der letzte Index festgehalten.

```
# Als Farbskale wird die Rotskala
# verwendet 'Reds'
plt.imshow( data[:,:,0], cmap='Reds' )
plt.colorbar()
plt.show()
```



Da die Bilddaten als Arrays gespeichert sind, sind viele der möglichen Optionen, z.B. zur Teilauswahl oder Operationen, verfügbar. Das untere Beispiel zeigt einen Ausschnitt im Rotkanal des Bildes.

```
bereich = np.array(data[450:500, 550:600,0], dtype=float)
plt.imshow( bereich, cmap="Greys" )
plt.colorbar()
```



💡 Zwischenübung: Bilder bearbeiten

Lesen Sie folgendes Bild vom Haspel Campus in Wuppertal ein: Bild Extrahieren Sie den blauen Anteil und lassen Sie sich die Zeile in der Mitte des Bildes ausgeben, so wie einen beliebigen Bildauschnitt.

```
Lösung
import numpy as np
import matplotlib.pyplot as plt
data = plt.imread('01-daten/campus_haspel.jpeg')
form = data.shape
print( "Form:", data.shape )
blau = data[:,:,2]
plt.imshow(blau, cmap='Blues')
zeile = data[int(form[0]/2),:,2]
print(zeile)
ausschnitt = data[10:50,10:50,:]
plt.imshow(ausschnitt)
Form: (3024, 4032, 3)
[221 220 220 ... 28 28 28]
  0 -
  5 -
 10 -
 15 -
 20 -
 25
 30 -
 35 -
             10
                     20
                              30
    0
```

9 Lernzielkontrolle

Herzlich willkommen zur Lernzielkontrolle!

Diese Selbstlernkontrolle dient dazu, Ihr Verständnis der bisher behandelten Themen zu überprüfen und Ihnen die Möglichkeit zu geben, Ihren Lernfortschritt eigenständig zu bewerten. Sie ist so konzipiert, dass Sie Ihre Stärken und Schwächen erkennen und gezielt an den Bereichen arbeiten können, die noch verbessert werden müssen.

Bitte nehmen Sie sich ausreichend Zeit für die Bearbeitung der Fragen und gehen Sie diese in Ruhe durch. Seien Sie ehrlich zu sich selbst und versuchen Sie, die Aufgaben ohne Hilfsmittel zu lösen, um ein realistisches Bild Ihres aktuellen Wissensstands zu erhalten. Sollten Sie bei einer Frage Schwierigkeiten haben, ist dies ein Hinweis darauf, dass Sie in diesem Bereich noch weiter üben sollten.

Viel Erfolg bei der Bearbeitung und beim weiteren Lernen!

Aufgabe 1

Wie wird das NumPy-Paket typischerweise eingebunden?

Aufgabe 2

Erstellen Sie mit Hilfe von NumPy die folgenden Arrays:

- 1. Erstellen sie aus der Liste [1, 2, 3] ein numPy Array
- 2. Ein eindimensionales Array, das die Zahlen von 0 bis 9 enthält.
- 3. Ein zweidimensionales Array der Form 3×33×3, das nur aus Einsen besteht.
- 4. Ein eindimensionales Array, das die Zahlen von 10 bis 50 (einschließlich) in Schritten von 5 enthält.

Aufgabe 3

Was ist der Unterschied zwischenden den Funktionen np.ndim, np.shape und np.size

Aufgabe 4

Frage zu Datentypen - Änderungen mit NumPy 2.0 abwarten

Aufgabe 5

Führen Sie mit den folgenden zwei Arrays diese mathematischen Operationen durch:

$$a = [5, 1, 3, 6, 4]$$
 und $b = [6, 5, 2, 6, 9]$

- 1. Addieren Sie beide Arrays
- 2. Berechnen Sie das elementweise Produkt von a und b
- 3. Addieren Sie zu jedem Eintrag von a 3 dazu

Aufgabe 6

```
a = [9, 2, 3, 1, 3]
```

- 1. Bestimmen Sie Mittelwert und Standardabweichung für das Array a
- 2. Bestimmen Sie Minimum und Maximum der Liste

Aufgabe 7

- 1. Extrahieren Sie die erste Zeile.
- 2. Extrahieren Sie die letzte Spalte.
- 3. Extrahieren Sie die Untermatrix, die aus den Zeilen 2 bis 4 und den Spalten 1 bis 3 besteht.

Aufgabe 8

array = np.arange(1, 21)

- 1. Ändern Sie die Form des Arrays in eine zweidimensionale Matrix der Form $4 \times 54 \times 5$.
- 2. Ändern Sie die Form des Arrays in eine zweidimensionale Matrix der Form $5\times45\times4$.
- 3. Ändern Sie die Form des Arrays in eine dreidimensionale Matrix der Form $2\times2\times52\times2\times5$.

- 4. Flachen Sie das dreidimensionale Array aus Aufgabe 3 wieder zu einem eindimensionalen Array ab.
- 5. Transponieren Sie die $4 \times 54 \times 5$ -Matrix aus Aufgabe 1.

Aufgabe 9

Mit welchen zwei Funktionen können Daten aus einer Datei gelsen und in einer Datei gespeichert werden?

Aufgabe 10

Sie möchten aus einem Bild die Bilddaten einer Farkomponente isolieren. Was müssen Sie dafür tun?

```
Lösung

Aufgabe 1

import numpy as np

Aufgabe 2

# 1.
np.array([1, 2, 3])

# 2.
print(np.arange(10))

# 3.
print(np.ones((3, 3)))

# 4.
print(np.arange(10, 51, 5))

[0 1 2 3 4 5 6 7 8 9]
[[1. 1. 1.]
[1. 1. 1.]
[1. 1. 1.]
[1. 1. 1.]
[10 15 20 25 30 35 40 45 50]
```

Aufgabe 3

np.ndim: Gibt die Anzahl der Dimensionen zurück np.shape: Gibt die Längen der einzelnen Dimensionen wieder np.size: Gibt die Anzahl aller Elemente aus

Aufgabe 4

???

Aufgabe 5

10 Übung

10.1 Aufgabe 1 Filmdatenbank

In der ersten Aufgabe wollen wir fiktive Daten für Filmbewertungen untersuchen. Das Datenset ist dabei vereinfacht und beinhaltet folgende Spalten:

- 1. Film ID
- 2. Benutzer ID
- 3. Bewertung

Hier ist das Datenset:

```
import numpy as np

bewertungen = np.array([
        [1, 101, 4.5],
        [1, 102, 3.0],
        [2, 101, 2.5],
        [2, 103, 4.0],
        [3, 104, 3.5],
        [3, 105, 4.0]
])
```

🥊 a) Bestimmen Sie die jemals niedrigste und höchste Bewertung, die je gegeben wurde

```
Lösung

niedrigste_bewertung = np.min(bewertungen[:,2])

print("Die niedrigste jemals gegebene Bertung ist:", niedrigste_bewertung)

hoechste_bewertung = np.max(bewertungen[:,2])

print("Die hoechste jemals gegebene Bertung ist:", hoechste_bewertung)

Die niedrigste jemals gegebene Bertung ist: 2.5

Die hoechste jemals gegebene Bertung ist: 5.0
```

🥊 b) Nennen Sie alle Bewertungen für Film 1

```
Lösung

bewertungen_film_1 = bewertungen[np.where(bewertungen[:,0]==1)]

print("Bewertungen für Film 1:\n", bewertungen_film_1)

Bewertungen für Film 1:

[[ 1. 101. 4.5]
 [ 1. 102. 3. ]]
```

Lösung

bewertungen_101 = bewertungen[np.where(bewertungen[:,1]==101)]

print("Bewertungen von Person 101:\n", bewertungen_101)

Bewertungen von Person 101:

[[1. 101. 4.5]
 [2. 101. 2.5]
 [3. 101. 5.]]

• d) Berechnen Sie die mittlere Bewertung für jeden Film und geben Sie diese nacheinander aus

```
Lösung

for ID in [1, 2, 3]:

mittelwert = np.mean(bewertungen[np.where(bewertungen[:,0]==ID),2])

print("Die Mittlere Bewertung für Film", ID, "beträgt:", mittelwert)

Die Mittlere Bewertung für Film 1 beträgt: 3.75

Die Mittlere Bewertung für Film 2 beträgt: 3.25

Die Mittlere Bewertung für Film 3 beträgt: 4.16666666666666
```

• e) Finden SIe den Film mit der höchsten Bewertung

```
Lösung

index_hoechste_bewertung = np.argmax(bewertungen[:,2])

print(bewertungen[index_hoechste_bewertung,:])

[ 3. 101. 5.]
```

💡 f) Finden Sie die Person mit den meisten Bewertungen

```
Lösung

einzigartige_person, anzahl = np.unique(bewertungen[:, 1],return_counts=True)

meist_aktiver_person = einzigartige_person[np.argmax(anzahl)]

print("Personen mit den meisten Bewertungen:", meist_aktiver_person)

Personen mit den meisten Bewertungen: 101.0
```

• g) Nennen Sie alle Filme mit einer Wertung von 4 oder besser.

• h) Film Nr. 4 ist erschienen. Der Film wurde von Person 102 mit einer Note von 3.5 bewertet. Fügen Sie diesen zur Datenbank hinzu.

```
Lösung
neue_bewertung = np.array([4, 102, 3.5])
bewertungen = np.append(bewertungen, [neue_bewertung], axis=0)
print(bewertungen)
       101.
               4.5
3.]
       102.
   1.
               2.5]
   2.
       101.
   2.
       103.
               4.]
 [ 3. 101.
               5.]
 3.
       104.
               3.5]
               4.]
 3.
       105.
   4.
       102.
               3.5]]
```

• i) Person 102 hat sich Film Nr. 1 nochmal angesehen und hat das Ende jetzt doch verstanden. Dementsprechend soll die Berwertung jetzt auf 5.0 geändert werden.

```
Lösung
bewertungen[(bewertungen[:, 0] == 1) &
            (bewertungen[:, 1] == 102), 2] = 5.0
print("Aktualisieren der Bewertung:\n", bewertungen)
Aktualisieren der Bewertung:
                4.5]
 [[ 1. 101.
   1. 102.
               5.]
   2. 101.
               2.5]
               4.]
   2.
      103.
               5.]
   3.
      101.
   3.
       104.
               3.5]
 3.
       105.
               4.]
 [ 4.
       102.
               3.5]]
```

10.2 Aufgabe 2 - Kryptographie - Caesar-Chiffre

In dieser Aufgabe wollen wir Text sowohl ver- als auch entschlüsseln.

Jedes Zeichen hat über die sogenannte ASCII-Tabelle einen Zahlenwert zugeordnet.

Tabelle 10.1: Ascii-Tabelle

Buchstabe	ASCII Code	Buchstabe	ASCII Code
a	97	n	110
b	98	О	111
\mathbf{c}	99	p	112
d	100	q	113
e	101	r	114
\mathbf{f}	102	\mathbf{S}	115
g	103	t	116
h	104	u	117
i	105	v	118
j	106	W	119
k	107	X	120
1	108	у	121
m	109	\mathbf{Z}	122

Der Einfachheit halber ist im Folgenden schon der Code zur Umwandlung von Buchstaben in Zahlenwerten und wieder zurück aufgeführt. Außerdem beschränken wir uns auf Texte mit kleinen Buchstaben.

Ihre Aufgabe ist nun die Zahlenwerte zu verändern.

Zunächste wollen wir eine einfache Caesar-Chiffre anwenden. Dabei werden alle Buchstaben um eine gewisse Anzahl verschoben. Ist Beispielsweise der der Verschlüsselungswert "1" wird aus einem A ein B, einem M, ein N. Ist der Wert "4" wird aus einem A ein E und aus einem M ein Q. Die Verschiebung findet zyklisch statt, das heißt bei einer Verschiebung von 1 wird aus einem Z ein A.

```
import numpy as np

# Funktion, die einen Buchstaben in ihren ASCII-Wert umwandelt
def buchstabe_zu_ascii(c):
    return np.array([ord(c)])

# Funktion, die einen ASCII-Wert in den passenden Buchstaben umwandelt
```

def ascii_zu_buchstabe(a):
 return chr(a)

• 1. Überlegen Sie sich zunächst wie man diese zyklische Verschiebung mathematisch ausdrücken könnte (Hinweis: Modulo Rechnung)

Lösung

$$\mathrm{ASCII}_{\mathrm{verschoben}} = (\mathrm{ASCII} - 97 + \mathrm{Versatz}) \text{ mod } 26 + 97$$

🥊 2. Schreiben Sie Code der mit einer Schleife alle Zeichen umwandelt.

Zunächst sollen alle Zeichen in Ascii Code umgewandelt werden. Dann wird die Formel auf die Zahlenwerte angewendet und schlussendlich in einer dritten schleife wieder alle Werte in Buchstaben übersetzt.

```
Lösung
import numpy as np
# Funktion, die einen Buchstaben in ihren ASCII-Wert umwandelt
def buchstabe_zu_ascii(c):
    return ord(c)
# Funktion, die einen ASCII-Wert in den passenden Buchstaben umwandelt
def ascii_zu_buchstabe(a):
    return chr(a)
klartext = "abrakadabra"
versatz = 3
umgewandelter_text = []
verschluesselte_zahl = []
verschluesselter_text= []
for buchstabe in klartext:
    umgewandelter_text.append(buchstabe_zu_ascii(buchstabe))
print(umgewandelter_text)
for zahl in umgewandelter_text:
    verschluesselt = (zahl - 97 + versatz) \% 26 + 97
    verschluesselte_zahl.append(verschluesselt)
print(verschluesselte_zahl)
for zahl in verschluesselte_zahl:
    verschluesselter_text.append(ascii_zu_buchstabe(zahl))
print(verschluesselter_text)
[97, 98, 114, 97, 107, 97, 100, 97, 98, 114, 97]
[100, 101, 117, 100, 110, 100, 103, 100, 101, 117, 100]
['d', 'e', 'u', 'd', 'n', 'd', 'g', 'd', 'e', 'u', 'd']
```

§ 3. Ersetzen Sie die Schleife, indem Sie die Rechenoperation mit einem NumPy-Array durchführen

```
Lösung
import numpy as np
# Funktion, die einen Buchstaben in ihren ASCII-Wert umwandelt
def buchstabe_zu_ascii(c):
   return ord(c)
# Funktion, die einen ASCII-Wert in den passenden Buchstaben umwandelt
def ascii_zu_buchstabe(a):
   return chr(a)
klartext = "abrakadabra"
versatz = 3
umgewandelter_text = []
verschluesselte_zahl = []
verschluesselter_text= []
for buchstabe in klartext:
    umgewandelter_text.append(buchstabe_zu_ascii(buchstabe))
print(umgewandelter_text)
umgewandelter_text = np.array(umgewandelter_text)
verschluesselte_zahl = (umgewandelter_text - 97 + versatz) % 26 + 97
print(verschluesselte_zahl)
for zahl in verschluesselte_zahl:
   verschluesselter_text.append(ascii_zu_buchstabe(zahl))
print(verschluesselter_text)
[97, 98, 114, 97, 107, 97, 100, 97, 98, 114, 97]
[100 101 117 100 110 100 103 100 101 117 100]
['d', 'e', 'u', 'd', 'n', 'd', 'g', 'd', 'e', 'u', 'd']
```

♀ 4. Schreiben sie den Code so um, dass der verschlüsselte Text entschlüsselt wird.

```
Lösung
import numpy as np
# Funktion, die einen Buchstaben in ihren ASCII-Wert umwandelt
def buchstabe_zu_ascii(c):
   return ord(c)
# Funktion, die einen ASCII-Wert in den passenden Buchstaben umwandelt
def ascii_zu_buchstabe(a):
   return chr(a)
versatz = 3
umgewandelter text = []
verschluesselte_zahl = []
entschluesselter_text= []
for buchstabe in verschluesselter_text:
    umgewandelter_text.append(buchstabe_zu_ascii(buchstabe))
print(umgewandelter_text)
umgewandelter_text = np.array(umgewandelter_text)
verschluesselte_zahl = (umgewandelter_text - 97 - versatz) % 26 + 97
print(verschluesselte_zahl)
for zahl in verschluesselte_zahl:
    entschluesselter_text.append(ascii_zu_buchstabe(zahl))
print(entschluesselter_text)
[100, 101, 117, 100, 110, 100, 103, 100, 101, 117, 100]
[ 97 98 114 97 107 97 100 97 98 114 97]
['a', 'b', 'r', 'a', 'k', 'a', 'd', 'a', 'b', 'r', 'a']
```